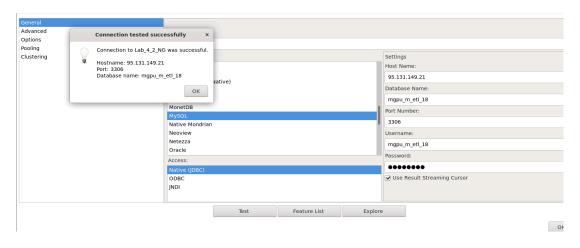
Департамент образования и науки города Москвы Государственное автономное образовательное учреждение высшего образования города Москвы «Московский городской педагогический университет» Институт цифрового образования Департамент информатики управления и технологий

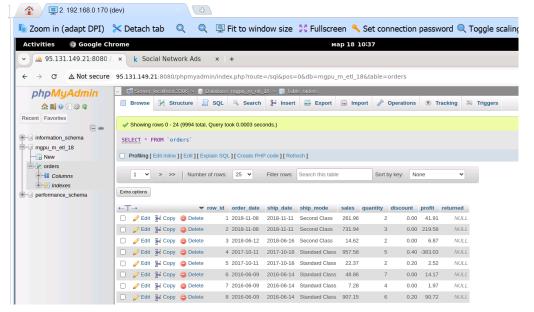
Нургалеева Гузель Рустэмовна БД-241м

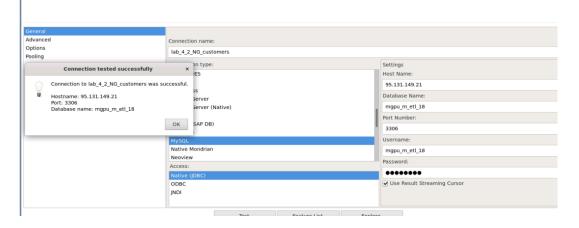
Data Engineering. Практическая работа 4-2.
Вариант задания: 18

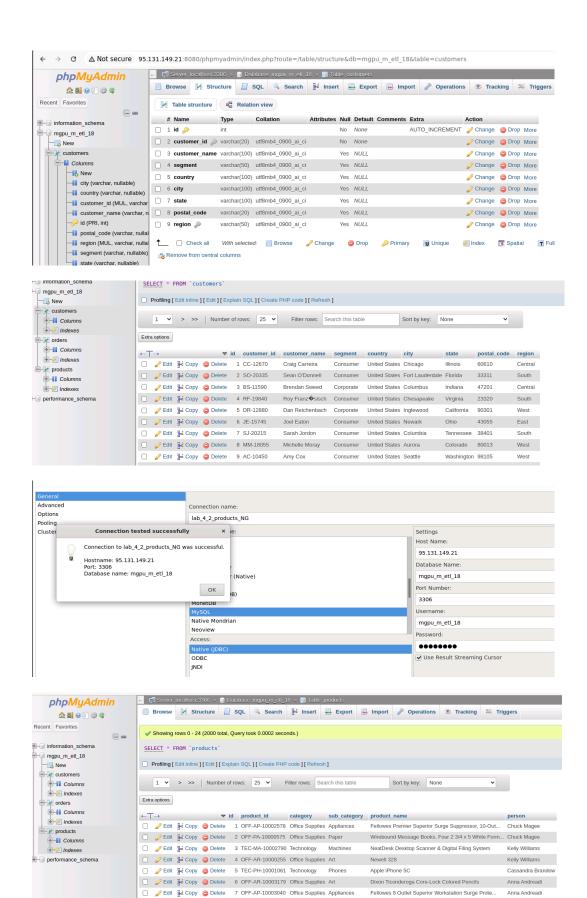
Направление подготовки/специальность 38.04.05 - Бизнес-информатика Бизнес-аналитика и большие данные (очная форма обучения)

Цель работы: получить практические навыки создания ETL-процесса для загрузки данных из CSV-файла в базу данных MySQL с использованием Pentaho Data Integration.

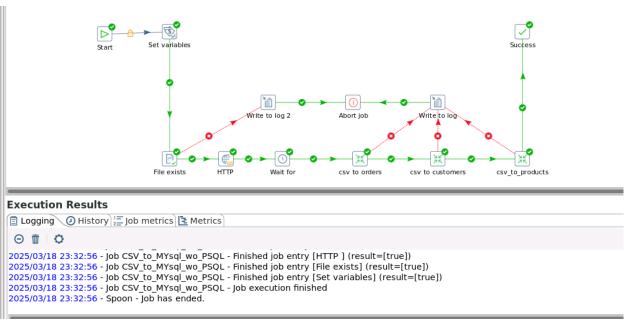


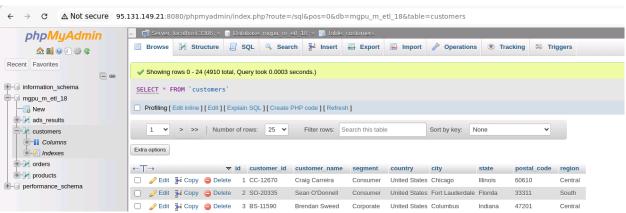


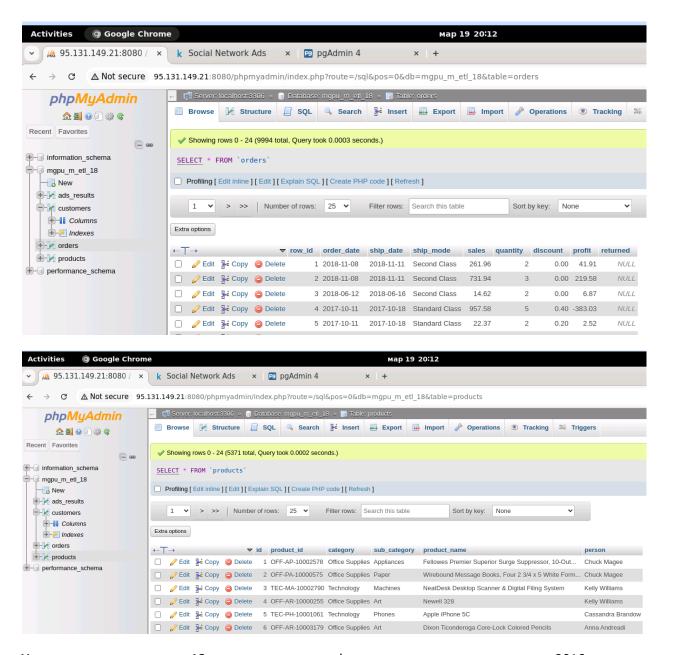




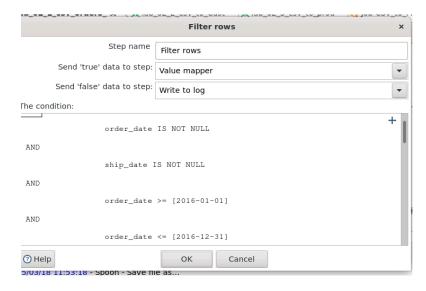
И вариант с использованием job

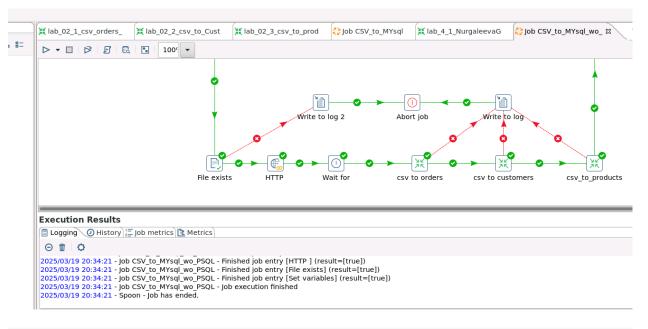


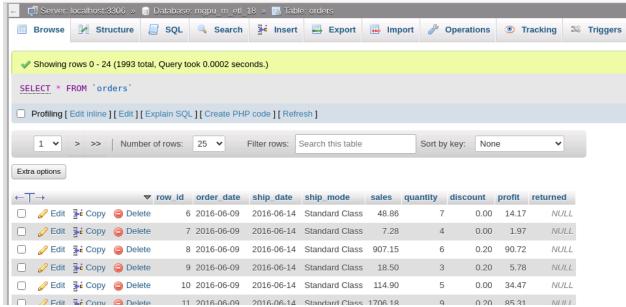




Индивидуальное задание 18: загрузить данные с фильтром по дате – только заказы 2016 года







Проверка:



SQL скрипты

```
-- Таблица заказов (основная информация о продажах)
CREATE TABLE orders (
row_id INT PRIMARY KEY,
order_date DATE,
ship_date DATE,
ship mode VARCHAR(50),
sales DECIMAL(10,2),
quantity INT,
discount DECIMAL(4,2),
profit DECIMAL(10,2),
returned TINYINT(1) DEFAULT 0 -- 1 = Yes, 0 = No
);
-- Таблица клиентов
DROP TABLE IF EXISTS customers;
CREATE TABLE customers (
id INT AUTO_INCREMENT PRIMARY KEY,
customer_id VARCHAR(20) NOT NULL,
customer name VARCHAR(100),
segment VARCHAR(50),
country VARCHAR(100),
city VARCHAR(100),
state VARCHAR(100),
postal_code VARCHAR(20),
region VARCHAR(50),
INDEX idx_customer_id (customer_id),
INDEX idx_region (region)
);
-- создаем таблицу products
DROP TABLE IF EXISTS products;
CREATE TABLE products (
id INT AUTO_INCREMENT PRIMARY KEY,
product id VARCHAR(20) NOT NULL,
category VARCHAR(50),
sub_category VARCHAR(50),
product_name VARCHAR(255),
person VARCHAR(100),
INDEX idx_product_id (product_id),
INDEX idx_category (category),
INDEX idx_subcategory (sub_category)
);
```

Контрольные вопросы

1. Что такое динамические соединения в РDI?

Динамические соединения в PDI позволяют:

- Использовать параметры подключения из внешних источников.
- Менять настройки соединения во время выполнения.
- Обрабатывать множество источников данных в одном процессе.

2. Как организовать обработку ошибок в трансформации?

Обработку ошибок можно организовать через занесение их в Log. После этого можно просмотреть журнал ошибок.

Также при варианте, в котором задействуется шаг с Log, можно предусмотреть последующим шагом остановку выполнения алгоритма.

Компоненты обработки ошибок.

- wrt-execution_error запись информации об ошибках.
- abrt-execution_error прерывание выполнения при критических ошибках.

3. Какие методы выявления дублей существуют?

- можно удалить дубли используя группировку по всем столбцам



Memory group by

- через использование функции unique rows



4. Как настроить параметризацию подключений?

Для настройки параметризации подключений в Pentaho можно использовать именованные параметры.

Эта система позволяет параметризовать преобразования и задания.

Чтобы настроить параметры, нужно:

- 1. Перейти в диалоговое окно настроек преобразования или задания и найти вкладку «Параметры».
- 2. Установить значения для параметров, которые будут использоваться во время выполнения. Если для параметра не установлено значение, используется значение по умолчанию.
- 3. В диалоговом окне выполнения преобразований и заданий можно установить значение для каждого определённого именованного параметра.

5. Какие компоненты PDI используются для объединения данных?

При помощи компонента **Pentaho Data Integration** также известного как Kettle. Он используется для интеграции данных из разных источников.

Один из востребованных шагов в Pentaho Data Integration — объединение (join) двух потоков данных. Для этого в настройках можно выбрать тип соединения (Inner, Left Outer, Right Outer, Full Outer) и указать ключи.

Обязательное требование для шага join — входные данные должны быть отсортированы по ключевым полям, для этого в Pentaho Data Integration применяется отдельный шаг **Sorter**